



Univerzitet u Beogradu
Elektrotehnički fakultet
Katedra za signale i sisteme



PROJEKAT

iz predmeta Analiza biomedicinske slike (13E054ABS)

Automatska segmentacija srčanih struktura na MR snimcima: 2D i 3D neuronskih mreža na ACDC bazi

Student

Vladan Bašić, 2022/0395

Predmetni nastavnik

prof. dr Milica Janković

Beograd, avgust 2026. godine

REZIME

U ovom projektu realizovan je kompletan postupak automatske segmentacije srčanih struktura na kinematografskim snimcima magnetnom rezonancom (cine-MR) u kratkoj osi. Sistem je razvijen i ispitan na javnoj bazi Automatic Cardiac Diagnosis Challenge (ACDC), koja sadrži snimke srca u krajnjoj diastoli i krajnjoj sistoli, zajedno sa ekspertskim oznakama leve komore, desne komore i miokarda. Realizovani lanac obrade obuhvata konverziju NIfTI podataka u HDF5 format uz očuvanje prostornih metapodataka, resamplovanje, normalizaciju intenziteta, centralno isecanje i dopunjavanje, podelu pacijenata na skupove za obuku i validaciju, obučavanje neuronskih mreža i evaluaciju nakon rekonstrukcije celih trodimenzionih volumena.

Upoređene su četiri arhitekture: FCN-8, standardni 2D U-Net, modifikovani 2D U-Net sa suženom putanjom nadodabiranja i anizotropni 3D U-Net. Pored standardne unakrsne entropije, za modifikovani 2D U-Net ispitane su ponderisana unakrsna entropija i Dice funkcija gubitka. Rezultati su dobijeni na fiksnom validacionom skupu od 20 pacijenata, odnosno 40 volumena kada se odvojeno posmatraju krajnja diastola i krajnja sistola. Najveći srednji Dice koeficijent postigao je modifikovani 2D U-Net obučen ponderisanom unakrsnom entropijom (0,875). Anizotropni 3D U-Net postigao je srednji Dice 0,862, uz najbolji rezultat za levu komoru (0,928), iako ima svega 5,48 miliona parametara.

Analiza potvrđuje značaj prostorne predobrade, podele po pacijentima, odgovarajuće funkcije gubitka i evaluacije na nivou volumena. U radu su prikazane krive učenja, rezultati po anatomskim strukturama, kvalitativni primeri predikcija i poređenje sa izvornim radom.

Sadržaj

REZIME	2
1 UVOD	4
2 METODOLOGIJA RADA	5
2.1 Baza podataka ACDC	5
2.2 Blok dijagram sistema	6
2.3 Konverzija i predobrada podataka	6
2.4 Arhitekture neuronskih mreža	7
2.5 Funkcije gubitka i obučavanje	8
2.6 Rekonstrukcija volumena i postobrada	9
2.7 Mere kvaliteta	9
3 REZULTATI I DISKUSIJA	10
3.1 Poređenje arhitektura	10
3.2 Uticaj funkcije gubitka	11
3.3 Krive učenja	11
3.4 Kvalitativna analiza predikcija	13
3.5 Poređenje sa izvornim radom	15
3.6 Ograničenja i mogućnosti unapređenja	15
4 ZAKLJUČAK	15
5 LITERATURA	17

1 UVOD

Kardiovaskularna magnetna rezonanca (CMR) omogućava neinvazivno sagledavanje anatomije i funkcije srca. Kinematografski MR snimak obuhvata više vremenskih trenutaka tokom srčanog ciklusa, dok niz preseka u kratkoj osi pokriva srce od baze do vrha. Za kvantitativnu analizu potrebno je odrediti granice šupljina leve i desne komore i mišićnog zida leve komore. Na osnovu tih kontura izračunavaju se zapremine na kraju dijasole i sistole, udarni volumen, ejekciona frakcija i masa miokarda. Smernice Društva za kardiovaskularnu magnetnu rezonancu preporučuju izveštavanje zapremina i ejekcionih frakcija obe komore jer su ove veličine važne za procenu srčane funkcije [3].

Leva komora (eng. *left ventricle*, LV) potiskuje oksigenisanu krv u sistemske cirkulaciju, dok desna komora (eng. *right ventricle*, RV) potiskuje krv prema plućima. Miokard (Myo) predstavlja mišićni zid srca; u ACDC zadatku označava se miokard leve komore između endokardne i epikardne konture. Krajnja dijasola (ED) odgovara trenutku najveće ispunjenosti komora, a krajnja sistola (ES) trenutku najveće kontrakcije. Ako su V_{ED} i V_{ES} zapremine komore u ta dva trenutka, ejekciona frakcija iznosi

$$EF = \frac{V_{ED} - V_{ES}}{V_{ED}} \cdot 100\% . \quad (1)$$

Zbog toga greška segmentacije ne utiče samo na izgled maske, već se neposredno prenosi na klinički značajne izvedene veličine.

Ručno iscrtavanje kontura na svakom preseku zahteva stručnost i vreme, a rezultat može zavisi od posmatrača. Automatska segmentacija nastoji da svakom pikselu ili vokselu dodeli jednu od četiri klase: pozadinu, RV, miokard ili LV. Konvolucione neuronske mreže postale su dominantan pristup analizi medicinskih slika zato što uče hijerarhijska obeležja direktno iz podataka i omogućavaju učenje od ulazne slike do guste izlazne maske [4].

Poseban problem kod MR snimaka srca jeste anizotropija. Rezolucija unutar preseka može biti manja od 2 mm, dok je rastojanje između preseka često 5--10 mm. Zbog toga susedni vokseli nemaju isto fizičko rastojanje u svim pravcima, a agresivna 3D obrada može izgubiti informacije duž ose preseka. Baumgartner i saradnici su na ACDC bazi pokazali da 2D mreže mogu biti konkurentnije od 3D mreža upravo zbog malog broja preseka, niske rezolucije kroz ravan i većeg broja 2D uzoraka za obuku [2].

Cilj ovog projekta bio je da se reprodukuje i proširi takav postupak: da se uporede FCN-8, 2D U-Net, modifikovani 2D U-Net i anizotropni 3D U-Net; izgradi ponovljiv postupak predobrade sa prostornim metapodacima; ispituju funkcije gubitka; i sprovede evaluacija 2D modela tek nakon rekonstrukcije kompletnog volumena.

2 METODOLOGIJA RADA


2.1 Baza podataka ACDC

Automatic Cardiac Diagnosis Challenge organizovan je u okviru radionice STACOM na konferenciji MICCAI 2017. Baza obuhvata 150 kinematografskih CMR pregleda snimljenih na uređajima jačine polja 1,5 T i 3 T. Zvanična podela sadrži 100 pacijenata sa javnim referentnim maskama za obuku i 50 pacijenata za testiranje, čije su reference prvobitno bile skrivene na evaluacionoj platformi [1, 11]. Svaki pacijent pripada jednoj od pet grupa, ravnomerno zastupljenih u obuci i testu (Tabela 1).

Tabela 1: Dijagnostičke grupe u bazi ACDC [1].

Oznaka	Naziv	Osnovna karakteristika	Obuka	Test
NOR	normalni ispitanici	uredna funkcija i dimenzije komora	20	10
MINF	prethodni infarkt miokarda	snižena LV ejekciona frakcija i regionalni poremećaj kontrakcije	20	10
DCM	dilatativna kardiomiopatija	proširena LV šupljina i snižena ejekciona frakcija	20	10
HCM	hipertrofična kardiomiopatija	zadebljan miokard uz očuvanu funkciju	20	10
ARV	abnormalna desna komora	povećana zapremina i/ili smanjena funkcija RV	20	10


Za svaki trening pregled dostupne su ručno iscrtane trodimenzionalne reference LV i RV šupljina i miokarda u ED i ES fazama. Slike imaju promenljivu rezoluciju: približno $0,70 \times 0,70$ do $1,92 \times 1,92$ mm unutar preseka i 5--10 mm kroz ravan [2]. Takva heterogenost zahteva resamplovanje uz očuvanje fizičkog razmaka voksela. U ovom projektu korišćeno je 100 javno označenih pacijenata. Podela je izvedena po pacijentima, a ne po presecima, kako preseki iste osobe ne bi dospeli u oba skupa. Sa semenom 42 i stratifikacijom prema dijagnozi izdvojeno je 80 pacijenata za obuku i 20 za validaciju. Time je u validaciji dobijeno 40 označenih volumena, po jedan ED i ES volumen za svakog pacijenta.



Slika 1: Primer MR preseka iz ACDC baze i ekspertske segmentacije desne komore, miokarda i leve komore.

2.2 Blok dijagram sistema

Ceo postupak prikazan je na Sl. 2. Ulazni podaci u NIfTI formatu najpre se prevode u HDF5 format uz očuvanje slike, oznake i prostornih metapodataka. Zatim se formiraju posebni 2D i 3D skupovi. Modeli se obučavaju na fiksnoj podeli pacijenata, nakon čega se 2D preseki ponovo slažu u volumene. Za svaku anatomsku klasu zadržava se najveća povezana komponenta, a izlaz se poredi sa ekspertskom referencom.



Slika 2: Blok dijagram realizovanog sistema za segmentaciju srčanih struktura.

2.3 Konverzija i predobrada podataka

Tokom konverzije učitavaju se slike, ekspertske maske i prostorni podaci iz NIfTI zaglavlja, a zatim se objedinjeno čuvaju u HDF5 formatu. Volumeni su predstavljeni matricama u redosledu osa $Z \times Y \times X$, a pojedinačni preseki u redosledu $Y \times X$. Uz intenzitete i oznake čuvaju se razmak voksela, afina transformacija, faza srčanog ciklusa, dijagnoza, identifikator pacijenta i broj vremenskog okvira. Prostorni podaci omogućavaju pravilno računanje fizičkih

rastojanja, dok klinički metapodaci omogućavaju ponovljivu stratifikovanu podelu pacijenata.

Za 2D mreže svaki presek se resampluje samo unutar ravni na $1,37 \times 1,37$ mm. Osa kroz preseke se ne interpolira, čime se izbegavaju artefakti nastali zbog velikog i promenljivog razmaka preseka. FCN-8 dobija ulaz 224×224 , dok oba U-Net modela koriste 396×396 . Slika se centralno iseče ili dopuni nulama do ciljne veličine. Intenziteti se standardizuju oduzimanjem srednje vrednosti i deljenjem standardnom devijacijom, dok se oznake resampluju interpolacijom najbližeg suseda kako ne bi nastale nepostojeće klase.

Za 3D mrežu volumen se resampluje na razmak $5,0 \times 2,5 \times 2,5$ mm u redosledu Z, Y, X, a zatim centralno dovodi na $60 \times 204 \times 204$ voksel. Trilinearna interpolacija se primenjuje na sliku, a najbliži sused na segmentacionu masku. Parametri prate izvorni rad [2] i predstavljaju kompromis između očuvanja anatomije i memorijskih zahteva 3D konvolucija. Sažetak je dat u Tabeli 2.

Tabela 2: Parametri predobrade po arhitekturi.

Arhitektura	Ciljni razmak	Ulazna veličina	Jedinica obuke
FCN-8	$1,37 \times 1,37$ mm	224×224	2D presek
2D U-Net	$1,37 \times 1,37$ mm	396×396	2D presek
modifikovani 2D U-Net	$1,37 \times 1,37$ mm	396×396	2D presek
anizotropni 3D U-Net	$5,0 \times 2,5 \times 2,5$ mm	$60 \times 204 \times 204$	3D volumen

2.4 Arhitekture neuronskih mreža

2.4.1 FCN-8

Potpuno konvolucionarna mreža (FCN) zamenjuje potpuno povezane slojeve klasifikacione mreže konvolucijama i time omogućava gustu predikciju klase za svaki piksel [5]. Realizovani FCN-8 koristi pet VGG-stil blokova sa konvolucijama 3×3 , ReLU aktivacijom i maksimalnim sažimanjem. Duboka mapa obeležja ima bogatu semantiku, ali malu prostornu rezoluciju. Zato se transponovanim konvolucijama nadodabira i sabira sa izlazima trećeg i četvrtog bloka. Ove preskočne veze kombinuju preciznu lokaciju iz plitkih slojeva sa kontekstom dubokih slojeva. Završno nadodabiranje faktorom osam vraća masku na dimenziju ulaza.

2.4.2 Standardni i modifikovani 2D U-Net

U-Net ima kontrakcionu putanju za izdvajanje konteksta i simetričnu ekspanzionu putanju za preciznu lokalizaciju [6]. Na svakom nivou dve konvolucije prate batch normalizacija i ReLU, a broj kanala raste sa dubinom. Tokom dekodovanja transponovana konvolucija povećava rezoluciju. Rezultat se nadovezuje sa mapom odgovarajućeg enkoderskog nivoa i obrađuje novim konvolucijama. Preskočne veze smanjuju gubitak detalja na granicama komora i

miokarda.

Modifikovani 2D U-Net zadržava isti enkoder i izlazne širine dekoderskih blokova, ali svaka transponovana konvolucija daje samo četiri kanala, koliko ima klasa. Nakon spajanja sa enkoderskom mapom naredne konvolucije ponovo formiraju potreban broj obeležja. Ideja je da puna širina same putanje nadodabiranja nije neophodna i da usko grlo može podstaći semantički smislenija obeležja [2]. Ovom izmenom broj parametara je smanjen sa 31,04 na 25,19 miliona, odnosno za približno 18,9%.

2.4.3 Anizotropni 3D U-Net

3D U-Net koristi volumetrijske operacije i neposredno uzima u obzir kontekst susednih preseka [7]. Međutim, standardno sažimanje faktorom dva po svim osama brzo bi uklonilo malobrojne preseke ACDC volumena. U realizovanoj anizotropnoj varijanti dubina se prepolovi samo na prvom nivou; naredna tri sažimanja rade samo u ravni, sa korakom (1, 2, 2). Dekoder primenjuje odgovarajuće anizotropne transponovane konvolucije. Model ima 5,48 miliona parametara, znatno manje od 2D varijanti, ali zbog trodimenzionih aktivacijai dalje zahteva mnogo GPU memorije.

Tabela 3: Uporedene arhitekture i broj parametara realizovanih modela.

Model	Broj parametara	Karakteristika
FCN-8	41 474 508	VGG-stil enkoder, preskočne veze sa pool3 i pool4 nivoa
2D U-Net	31 044 484	simetrični enkoder--dekoder sa nadovezivanjem obeležja
modifikovani 2D U-Net	25 188 212	transponovane konvolucije sužene na broj klasa
anizotropni 3D U-Net	5 476 356	samo jedno sažimanje duž ose preseka

2.5 Funkcije gubitka i obučavanje

Za višeklasnu segmentaciju standardna unakrsna entropija za N lokacija i K klasa glasi

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_{nk} \log p_{nk}, \quad (2)$$

gde je t_{nk} binarna referentna oznaka, a p_{nk} softmax verovatnoća. Pošto pozadina zauzima mnogo više piksela od srčanih struktura, ispitana je i ponderisana varijanta sa težinom 0,1 za pozadinu i 0,3 za svaku ciljnu klasu. Time greške na RV, miokardu i LV dobijaju veći relativni uticaj.

Treća mogućnost neposredno optimizuje meko preklapanje ciljnih klasa. U

skladu sa reprodukovanim radom korišćen je oblik

$$\mathcal{L}_{Dice} = 1 - \frac{\sum_{k=2}^K \sum_{n=1}^N t_{nk} p_{nk} + \varepsilon}{\sum_{k=2}^K \sum_{n=1}^N (t_{nk} + p_{nk}) + \varepsilon}, \quad (3)$$

bez faktora dva u brojiocu. Mali ε sprečava deljenje nulom.

Svi modeli koriste batch normalizaciju posle konvolucionih i transponovanih konvolucionih slojeva. Ona stabilizuje raspodelu aktivacija unutar mini-grupe i omogućava pouzdaniju obuku dubokih mreža. Optimizacija je izvedena algoritmom Adam, koji prilagođava korak na osnovu prvog i drugog momenta gradijenta. Sačuvana podešavanja konkretnih eksperimenata data su u Tabeli 4. Sve obuke izvršene su na CUDA grafičkom procesoru, sa semenom 42 i bez težinske regularizacije.

Tabela 4: Podešavanja sačuvanih eksperimenata. CE označava unakrsnu entropiju.

Model	Epohe	Mini-grupa	Korak učenja	Gubitak	Trening uzorci	Valid. uzorci	Najbolja epoha
FCN-8	100	16	0,001	CE	1538 preseka	374 preseka	100
2D U-Net	200	4	0,0001	CE	1538 preseka	374 preseka	30
mod. 2D U-Net	100	8	0,01	ponderisana CE	1538 preseka	374 preseka	66
mod. 2D U-Net	100	8	0,01	Dice	1538 preseka	374 preseka	72
3D U-Net	100	1	0,01	CE	160 volumena	40 volumena	97

2.6 Rekonstrukcija volumena i postobrada

Metrike prijavljene tokom obuke 2D mreža računaju se nad presecima u mini-grupama i zato nisu dovoljne za poređenje sa volumetrijskim rezultatima. Tokom evaluacije preseki se grupišu prema identifikatoru pacijenta i broju vremenskog okvira, uređuju po anatomskom položaju i slažu u 3D masku. Za 3D U-Net predikcija je već volumetrijska.

U automatskim maskama povremeno se pojavljuju mala izolovana ostrva. Za svaku foreground klasu izdvaja se šest-susedstvom najveća povezana komponenta, dok se ostali vokseli vraćaju u pozadinu. Ovaj postupak je jednostavan, anatomske opravdan za jednu komoru i smanjuje osetljivost Hausdorffovog rastojanja na udaljene lažno pozitivne komponente. Isti pristup korišćen je u izvornom radu, gde je imao mali uticaj na Dice, ali primetan uticaj na HD [2].

2.7 Mere kvaliteta

Nijedna mera sama ne opisuje sve osobine segmentacije. Dice meri preklapanje regiona, dok ASSD i HD koriste položaj granice. Zajedno daju potpuniju sliku grešaka [10].

Za predikciju P i referencu G , Dice koeficijent je

$$Dice(P, G) = \frac{2|P \cap G|}{|P| + |G|}. \quad (4)$$

Vrednost jedan označava potpuno preklapanje, a nula odsustvo preklapanja.

Srednji foreground Dice u ovom radu predstavlja prosek za RV, miokard i LV preko svih 40 validacionih volumena.

Ako su S_P i S_G skupovi tačaka na površinama maski, a $d(x, S) = \min_{y \in S} \|x - y\|$, prosečno simetrično rastojanje površina iznosi

$$ASSD(P, G) = \frac{\sum_{p \in S_P} d(p, S_G) + \sum_{g \in S_G} d(g, S_P)}{|S_P| + |S_G|}, \quad (5)$$

dok je Hausdorffovo rastojanje

$$HD(P, G) = \max \left\{ \max_{p \in S_P} d(p, S_G), \max_{g \in S_G} d(g, S_P) \right\}. \quad (6)$$

HD opisuje najgoru graničnu grešku i veoma je osetljiv na izdvojene tačke, dok ASSD predstavlja prosečnu grešku konture. Kada je poznat razmak voksel, Euklidsko rastojanje treba računati u fizičkim koordinatama i prijaviti u milimetrima.


3 REZULTATI I DISKUSIJA

3.1 Poređenje arhitektura

Tabela 5 prikazuje volumetrijske rezultate najboljeg sačuvanog modela za svaku arhitekturu. Najveći srednji Dice postigao je modifikovani 2D U-Net sa ponderisanom unakrsnom entropijom: 0,875. Isti model je najbolji za RV (0,859) i miokard (0,846). Anizotropni 3D U-Net je najbolji za LV sa Dice koeficijentom 0,928 i ima srednji rezultat 0,862, praktično jednak standardnom 2D U-Net modelu.

Tabela 5: Rezultati na 40 rekonstruisanih validacionih volumena. Najbolji Dice rezultati su podebljani.

Model	Srednji Dice	Dice RV	Dice Myo	Dice LV	ASSD [†]	HD [†]
FCN-8	0,847	0,825	0,802	0,912	0,749	7,605
2D U-Net	0,862	0,848	0,833	0,905	1,421	8,332
mod. 2D U-Net (pond. CE)	0,875	0,859	0,846	0,921	0,878	7,648
anizotropni 3D U-Net	0,862	0,841	0,817	0,928	0,431	5,460



Slika 3: Poređenje srednjeg Dice koeficijenta i rezultata po srčanim strukturama.

Modifikacija 2D U-Net modela smanjila je broj parametara za 18,9% u odnosu na standardni U-Net, a istovremeno povećala srednji volumetrijski Dice sa 0,862 na 0,875. Rezultat podržava pretpostavku da široka putanja transponovanih konvolucija nije neophodna za ovaj zadatak. Ipak, poređenje nije čista ablacija arhitekture: modeli su obučeni različitim koracima učenja, brojem epoha i funkcijama gubitka, pa deo razlike može poticati i od optimizacije.

FCN-8 postiže najniži srednji Dice, 0,847, ali je njegov rezultat za LV i dalje visok (0,912). Niži rezultati RV i miokarda odgovaraju njihovoj složenijoj geometriji: RV ima tanji i nepravilniji oblik, dok je miokard prstenasta struktura čija mala greška obe konture značajno menja preklapanje. Sličan obrazac vidi se i u izvornom radu, gde je LV najlakša od tri strukture za segmentaciju [2].

3.2 Uticaj funkcije gubitka

Za modifikovani 2D U-Net upoređene su ponderisana unakrsna entropija i Dice gubitak. Ponderisana entropija povećala je srednji Dice za 0,058 (Tabela 6). Najveća razlika javlja se kod RV: 0,859 prema 0,731. Dice gubitak je zadržao dobre rezultate za LV i miokard, ali je u delu volumena promašivao RV, što značajno smanjuje proseku. Rezultat je saglasan zaključku da je direktna optimizacija njihove varijante Dice gubitka bila slabija od unakrsne entropije [2].


Tabela 6: Uticaj funkcije gubitka na modifikovani 2D U-Net.

Funkcija gubitka	Srednji Dice	RV	Myo	LV
ponderisana unakrsna entropija	0,875	0,859	0,846	0,921
Dice gubitak	0,818	0,731	0,812	0,910

3.3 Krive učenja


Na Sl. 4 prikazan je validacioni Dice tokom prvih 100 epoha najboljeg sačuvanog eksperimenta za svaku arhitekturu. FCN-8 se poboljšavao do poslednje

epohe. Standardni 2D U-Net dostigao je najbolji zabeleženi validacioni Dice već u 30. epohi, posle čega su prisutne oscilacije i slabiji krajnji rezultat. Modifikovani 2D U-Net sa ponderisanom entropijom bio je najbolji u 66. epohi, dok je 3D U-Net dostigao maksimum u 97. epohi. Pad 3D validacionog Dice koeficijenta u poslednjim epohama, uz mali broj volumena i mini-grupu veličine jedan, pokazuje osetljivost 3D obuke na optimizaciju.



Slika 4: Promena validacionog srednjeg foreground Dice koeficijenta tokom obuke.


Detaljnije krive najboljeg modifikovanog 2D U-Net eksperimenta prikazane su na Sl. 5. Trening gubitak nastavlja da opada, dok validacioni gubitak nakon minimuma raste i osciluje. Ovakav razmak trening i validacionih krivih ukazuje na preobučavanje i opravdava izbor parametara iz epohe sa najboljim validacionim rezultatom umesto poslednje epohe. Validacioni Dice po klasama pokazuje da LV najbrže dostiže visoke vrednosti, dok RV ima najveću varijabilnost.



Slika 5: Gubitak, tačnost i Dice koeficijenti tokom obuke modifikovanog 2D U-Net modela.

3.4 Kvalitativna analiza predikcija

Slika 6 prikazuje pet položaja kroz ED volumen pacijenta 092, od nižeg prema višem delu anatomije. Leva kolona sadrži MR preseke, srednja predikcije modifikovanog 2D U-Net modela, a desna ekspertske reference. Boje odgovaraju RV, miokardu i LV. Za prikazanih pet preseka srednji Dice prisutnih foreground klasa iznosi 0,9265.



Slika 6: Predikcije modifikovanog 2D U-Net modela i ekspertske maske kroz ED volumen pacijenta 092.

U centralnim presecima, gde su strukture velike i kontrastne, slaganje je veoma dobro. Najveće razlike očekivano se javljaju u bazalnim i apikalnim delovima, gde strukture zauzimaju mali broj piksela, njihov oblik se brzo menja između preseka, a delimični volumenski efekat zamagljuje granice. Miokard je posebno osetljiv jer je ograničen dvema bliskim konturama. Postobrada uklanja izolovane regione, ali ne može ispraviti sistematsko pomeranje konture ili potpuno

propuštenu strukturu.

3.5 Poređenje sa izvornim radom

Da bi se rezultat stavio u kontekst, u Tabeli 7 lokalni Dice po arhitekturi poređen je sa prosekom ED i ES vrednosti iz rada Baumgartnera i saradnika. Poređenje je orijentaciono: u ovom radu dimenzije se zadržavaju dopunjavanjem pri konvoluciji, optimizaciona podešavanja nisu identična izvornim, a objavljene vrednosti su prosečene po fazama.

Tabela 7: Srednji Dice ovog projekta i ED/ES prosek objavljenih rezultata [2].

Arhitektura	Ovaj projekat	Izvorni rad	Razlika
FCN-8	0,847	0,902	−0,055
2D U-Net	0,862	0,911	−0,049
modifikovani 2D U-Net	0,875	0,914	−0,039
anizotropni 3D U-Net	0,862	0,859	+0,003

Rezultati potvrđuju glavni obrazac izvornog rada: razlike između dobro podešenih arhitektura nisu velike, 2D modeli koriste više uzoraka i bolje čuvaju detalje unutar ravni, dok 3D model koristi prostorni kontekst uz nižu rezoluciju i veće memorijske zahteve.

3.6 Ograničenja i mogućnosti unapređenja

Glavno ograničenje je evaluacija na jednoj fiksnoj podeli od 20 pacijenata. Iako je podela stratifikovana i sprečava curenje preseka, rezultat zavisi od konkretnog izbora pacijenata. Unakrsna validacija po pacijentima ili više ponovljenih podela omogućile bi procenu varijanse i intervala pouzdanosti.

Dalji rad može obuhvatiti augmentaciju intenziteta i geometrije, kombinovane Dice--CE funkcije, 95-procentni Hausdorff radi manje osetljivosti na pojedinačne autlajere, ansamble modela i izračunavanje kliničkih mera kao što su zapremine, masa miokarda i ejekciona frakcija. Za kliničku primenu neophodna je i eksterna validacija na podacima drugih centara i proizvođača uređaja, kao i analiza neuspešnih slučajeva, robusnosti i nesigurnosti predikcija.

Dalji rad se takođe može baviti poređenjem modela treniranih od nule sa fine-tune-ovanim predtreniranim modelima za segmentaciju, kao i 3D modela treniranih na boljim grafičkim karticama.

4 ZAKLJUČAK

U projektu je realizovan ponovljiv postupak za višeklasnu segmentaciju srčanih struktura na ACDC kinematografskim MR snimcima. Metodologija obuhvata očuvanje prostornih metapodataka, posebnu 2D i 3D predobradu,

dijagnostički stratifikovanu podelu po pacijentima, poređenje četiri konvolucione arhitekture i volumetrijsku evaluaciju uz postobradu najveće povezane komponente.

Od upoređenih modela najbolji srednji Dice koeficijent, 0,875, postigao je modifikovani 2D U-Net obučen ponderisanom unakrsnom entropijom. Ovaj model bio je najbolji za desnu komoru i miokard, dok je anizotropni 3D U-Net postigao najbolji Dice leve komore, 0,928. Suženje putanje nadodabiranja smanjilo je broj parametara 2D U-Net modela za približno 18,9% i istovremeno povećalo rezultat u odnosu na sačuvani standardni U-Net eksperiment. Ponderisana unakrsna entropija bila je znatno uspešnija od ispitane Dice funkcije gubitka, naročito za RV.

Krive učenja i kvalitativni prikazi pokazuju da mreže uspešno izdvajaju sve tri strukture, ali i da su rezultati osetljivi na položaj preseka, mali broj 3D uzoraka i preobučavanje. Poređenje sa izvornim radom pokazuje isti opšti odnos arhitektura i potvrđuje da jednostavnija 2D obrada može biti veoma efikasna kod anizotropnih volumena. Projekat zato predstavlja uspešnu tehničku reprodukciju i dobru osnovu za dalju, strože kontrolisanu evaluaciju.

5 LITERATURA

Bibliografija

- [1] O. Bernard, A. Lalande, C. Zotti, F. Cervenansky, et al., "Deep Learning Techniques for Automatic MRI Cardiac Multi-structures Segmentation and Diagnosis: Is the Problem Solved?", *IEEE Transactions on Medical Imaging*, vol. 37, no. 11, str. 2514--2525, 2018. DOI: <https://doi.org/10.1109/TMI.2018.2837502>.
- [2] C. F. Baumgartner, L. M. Koch, M. Pollefeys i E. Konukoglu, "An Exploration of 2D and 3D Deep Learning Techniques for Cardiac MR Image Segmentation", u *Statistical Atlases and Computational Models of the Heart, STACOM 2017*, LNCS 10663, str. 111--119, 2018. <https://arxiv.org/abs/1709.04496>.
- [3] J. Schulz-Menger, D. A. Bluemke, J. Bremerich, et al., "Standardized image interpretation and post-processing in cardiovascular magnetic resonance - 2020 update", *Journal of Cardiovascular Magnetic Resonance*, vol. 22, art. 19, 2020; i SCMR smernice za izveštavanje CMR pregleda, 2022. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9052489/>.
- [4] G. Litjens, T. Kooi, B. E. Bejnordi, et al., "A survey on deep learning in medical image analysis", *Medical Image Analysis*, vol. 42, str. 60--88, 2017. DOI: <https://doi.org/10.1016/j.media.2017.07.005>.
- [5] J. Long, E. Shelhamer i T. Darrell, "Fully Convolutional Networks for Semantic Segmentation", u *Proc. CVPR*, str. 3431--3440, 2015. https://openaccess.thecvf.com/content_cvpr_2015/html/Long_Fully_Convolutional_Networks_2015_CVPR_paper.html.
- [6] O. Ronneberger, P. Fischer i T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation", u *MICCAI*, LNCS 9351, str. 234--241, 2015. DOI: https://doi.org/10.1007/978-3-319-24574-4_28.
- [7] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox i O. Ronneberger, "3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation", u *MICCAI*, LNCS 9901, str. 424--432, 2016. DOI: https://doi.org/10.1007/978-3-319-46723-8_49.
- [10] A. A. Taha i A. Hanbury, "Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool", *BMC Medical Imaging*, vol. 15, art. 29, 2015. DOI: <https://doi.org/10.1186/s12880-015-0068-x>.
- [11] CREATIS, "Automated Cardiac Diagnosis Challenge (ACDC)", zvanična stranica baze i izazova. <https://www.creatis.insa-lyon.fr/Challenge/acdc/>. Pristupljeno: avgust 2026.