



Univerzitet u Beogradu
Elektrotehnički fakultet
Katedra za signale i sisteme



DIPLOMSKI RAD

Segmentacija srčanih struktura na snimcima magnetne rezonance

Student

Vladan Bašić, 2022/0395

Mentor

prof. dr Milica Janković

Beograd, septembar 2026. godine

REZIME

U ovom radu realizovan je postupak automatske segmentacije desne komore, miokarda i leve komore na kinematografskim MR snimcima srca u kratkoj osi (eng. *short-axis cardiac MRI*). Postupak obuhvata konverziju NIfTI podataka u HDF5 uz očuvanje prostornog razmaka vokseli i afine transformacije, resamplovanje, normalizaciju intenziteta, obuku neuronskih mreža i evaluaciju nakon rekonstrukcije celih trodimenzionalnih volumena. Posebna pažnja posvećena je promenljivoj i anizotropnoj rezoluciji ACDC baze.

Upoređene su sledeće arhitekture neuronskih mreža: *FCN-8*, standardni 2D *U-Net*, modifikovani 2D *U-Net* i anizotropni 3D *U-Net*. Umesto jedne fiksne podele, 100 označenih trening pacijenata podeljeno je deterministički na pet dijagnostički stratifikovanih *foldova*. U svakom *foldu* obučava se na 80, a validira na 20 pacijenata; svaka od pet dijagnostičkih grupa zastupljena je sa 16/4 pacijenta. Najveći srednji volumetrijski *Dice* koeficijent u unakrsnoj validaciji postiže standardni 2D *U-Net*, $0,9025 \pm 0,0064$. Njegov ansambl od pet modela postiže *Dice* 0,9109 na odvojenih 50 test pacijenata.

Metrike *Dice*, *Average Symmetric Surface Distance* (ASSD) i Hausdorffovo rastojanje računaju se na rekonstruisanim volumenima, nakon zadržavanja najveće povezane komponente svake ciljne klase. Rastojanja se računaju sa fizičkim razmakom u milimetrima.

Sadržaj

REZIME	2
1 UVOD	4
2 METODOLOGIJA RADA	5
2.1 Baza podataka ACDC	5
2.2 Blok dijagram sistema	6
2.3 Konverzija, prostorni razmak i predobrada	6
2.4 Arhitekture neuronskih mreža	7
2.5 Funkcije gubitka i obučavanje	10
2.6 Rekonstrukcija volumena i postobrada	11
2.7 Mere kvaliteta	11
3 REZULTATI I DISKUSIJA	12
3.1 Poređenje arhitektura	12
3.2 Uticaj petostruke validacije	14
3.3 Završna evaluacija ansambla	15
3.4 Krive učenja	15
3.5 Kvalitativna analiza predikcija	16
3.6 Diskusija	19
3.7 Ograničenja i mogućnosti unapređenja	20
4 ZAKLJUČAK	21
5 LITERATURA	23

1 UVOD

Kardiovaskularna magnetna rezonanca (CMR) omogućava neinvazivno sagledavanje anatomije i funkcije srca. Kinematografski MR snimak obuhvata više vremenskih trenutaka tokom srčanog ciklusa, dok niz preseka u kratkoj osi (eng. *short-axis cardiac MRI*) pokriva srce od baze do vrha. Za kvantitativnu analizu potrebno je odrediti granice šupljina leve i desne komore i mišićnog zida leve komore. Na osnovu tih kontura izračunavaju se zapremine na kraju dijasole i sistole, udarni volumen, ejekciona frakcija i masa miokarda. Smernice za CMR analizu preporučuju izveštavanje zapremina i ejekcionih frakcija obe komore, jer su ove veličine važne za procenu srčane funkcije [1].

Leva komora (eng. *left ventricle*, LV) potiskuje oksigenisanu krv u sistemsku cirkulaciju, dok desna komora (eng. *right ventricle*, RV) potiskuje krv prema plućima. Miokard (Myo) predstavlja mišićni zid leve komore između endokardne i epikardne konture. Krajnja dijasola (ED) odgovara najvećoj ispunjenosti komora, a krajnja sistola (ES) njihovoj najvećoj kontrakciji. Ako su V_{ED} i V_{ES} zapremine komore, ejekciona frakcija iznosi

$$EF = \frac{V_{ED} - V_{ES}}{V_{ED}} \cdot 100 \% . \quad (1)$$

Ručno iscrtavanje kontura zahteva stručnost i vreme, a rezultat može zavisi od posmatrača. Automatska segmentacija svakom pikselu ili vokselu dodeljuje pozadinu, RV, miokard ili LV. Konvolucione neuronske mreže uče hijerarhijska obeležja direktno iz slike i pogodne su za ovu gustu višeklasnu klasifikaciju [2].

Automatska segmentacija LV, RV i miokarda primenjuje se na ultrazvučnim snimcima srca, snimcima kompjuterizovane tomografije (CT) i snimcima magnetne rezonance (MRI). Iz dobijenih maski mogu se izračunati zapremine komora, ejekciona frakcija, debljina zida i masa miokarda, pri čemu se kvalitet slike i geometrija podataka bitno razlikuju između modaliteta [3].

Ovaj rad se dalje ograničava na *cine*-MRI snimke srca u kratkoj osi. Za takve snimke Baumgartner i saradnici uporedili su FCN-8, standardni i modifikovani 2D U-Net i 3D U-Net za segmentaciju LV, RV i miokarda, dok su Bernard i saradnici objedinjeno ocenili metode na ACDC skupu podataka iz 2017 [4, 5]. Zato su isti anatomske ciljevi, skup podataka i porodice mreža polazište ovog rada.

Poseban problem kod MR snimaka srca jeste anizotropija. Volumeni snimaka ACDC baze podataka imaju *in-plane* razmak približno 0,703–1,953 mm, a razmak duž ose preseka 5–10 mm. Zbog toga susedni vokseli nemaju isto fizičko rastojanje u svim pravcima, pa agresivna 3D obrada može izgubiti informaciju duž ose preseka. Mali broj preseka, niska rezolucija kroz ravan i veći broj 2D uzoraka za obuku zato daju prednost 2D pristupima u odnosu na 3D mreže.

Isensee i saradnici su za ACDC izazov koristili ansambl 2D i 3D mreža U-Net za segmentaciju LV, RV i miokarda u svim vremenskim trenucima srčanog ciklusa. Iz dobijenih vremenskih nizova maski izdvajali su klinički motivisana obeležja, koja su potom koristili za automatsku klasifikaciju bolesti [6].

Khened i saradnici su predložili gusto povezanu potpuno konvolucionu mrežu sa *DenseNet* blokovima i početnim *Inception* slojem. Segmentacije LV, RV i miokarda zatim su koristili za izdvajanje kliničkih obeležja i klasifikaciju bolesti pomoću *random forest* algoritma [7].

Cilj rada je reprodukcija i proširenje postupka Baumgartnera i saradnika: poređenje FCN-8, standardnog i modifikovanog 2D U-Net-a i anizotropnog 3D U-Net-a, uz očuvanje prostornih metapodataka, normalizaciju fizičke skale i procenu kvaliteta na nivou celih volumena. U odnosu na raniji eksperiment sa jednom podelom, ovde se koristi deterministička dijagnostički stratifikovana petostruka validacija i odvojena evaluacija petomodelnog ansambla.

2 METODOLOGIJA RADA

2.1 Baza podataka ACDC

Automatic Cardiac Diagnosis Challenge sadrži 150 cine-CMR pregleda sa ED i ES referencama za LV, RV i miokard [5, 8]. Sto pacijenata 001--100 korišćeno je isključivo za obuku i unakrsnu validaciju, dok 50 pacijenata 101--150 ostaje odvojeno za završnu lokalnu evaluaciju ansambla. Dijagnoze DCM, HCM, MINF, NOR i RV ravnomerno su zastupljene, Tabela 1.


Tabela 1: Dijagnostičke grupe u ACDC bazi [5].

Oznaka	Naziv	Osnovna karakteristika	Obuka	Test
NOR	normalni ispitanici	uredna funkcija i dimenzije komora	20	10
MINF	prethodni infarkt miokarda	snižena LV ejekciona frakcija i regionalni poremećaj kontrakcije	20	10
DCM	dilatativna kardiomiopatija	proširena LV šupljina i snižena ejekciona frakcija	20	10
HCM	hipertrofična kardiomiopatija	zadebljan miokard uz očuvanu funkciju	20	10
RV	abnormalna desna komora	povećana zapremina i/ili smanjena funkcija RV	20	10


Pacijenti se dele sa semenom 42 na pet *foldova*. Svaki *fold* ima 80 pacijenata za obuku i 20 za validaciju, pri čemu su svi preseki i obe faze jednog pacijenta u istom *foldu*. Time se sprečava curenje informacija između obuke i validacije i omogućava procena varijabilnosti rezultata. Primer MR preseka i odgovarajuće ekspertske segmentacije prikazan je na Sl. 1.

Primer MR preseka i ekspertske segmentacije

Jedan presek MRI snimka




Ekspertska segmentacija



Slika 1: Primer MR preseka iz ACDC baze i ekspertske segmentacije desne komore, miokarda i leve komore.

2.2 Blok dijagram sistema

Ulazni NIfTI podaci najpre se prevode u HDF5 format uz očuvanje slike, oznake i prostornih metapodataka. Zatim se formiraju posebni 2D i 3D skupovi. U svakom *foldu* model vidi samo pacijente za obuku, dok se za evaluaciju čuvaju težine iz epohe sa najboljim validacionim *foreground Dice* rezultatom. Nakon predikcije, 2D preseki se ponovo slažu u volumene, uklanjaju se male izolovane komponente i izlaz se poredi sa ekspertskom referencom. Blok dijagram sistema prikazan je na Sl. 2.




Slika 2: Blok dijagram sistema za segmentaciju.

2.3 Konverzija, prostorni razmak i predobrada

NIfTI slike i maske prevode se u HDF5 uz čuvanje identifikatora pacijenta, dijagnoze, faze, oblika volumena, affine transformacije i razmaka u redosledu $Z \times Y \times X$. Uz intenzitete i oznake čuvaju se i broj vremenskog okvira i položaj preseka. Prostorni razmak koristi se za resamplovanje i računanje fizičkih rastojanja, dok identifikator pacijenta i dijagnoza određuju stratifikovanu podelu.

Prostorni razmak nije dodatni ulazni kanal mreže. Raspodela izvornih razmaka vokseli i ciljni razmaci primenjeni u predobradi prikazani su na Sl. 3.



Slika 3: Raspodela izvornog razmaka vokseli trening pacijenata. Crvene linije označavaju ciljne razmake na koje su slike resamplovane prilikom 2D i 3D predobrade.

Za 2D mreže svaki presek se resampluje samo unutar ravni na $1,37 \times 1,37$ mm. Osa kroz preseke se ne interpolira, čime se izbegavaju artefakti pri velikom i promenljivom razmaku preseka. FCN-8 koristi 224×224 , a oba U-Net modela 396×396 piksela. Za 3D model volumen se resampluje na $5,0 \times 2,5 \times 2,5$ mm i centralno dovodi na $60 \times 204 \times 204$ vokseli. Na slikama se koristi linearna, a na maskama interpolacija najbližeg suseda. Intenziteti se standardizuju po slici, dok se preveliki ulazi centralno isecaju, a manji dopunjuju nulama. Tok obrade, od ulaznih NIfTI podataka do evaluacionih metrika, sažeto je prikazan na Sl. 2.

Tabela 2: Parametri predobrade po arhitekturi.

Arhitektura	Ciljni razmak	Ulazna veličina	Jedinica obuke
FCN-8	$1,37 \times 1,37$ mm	224×224	2D presek
2D U-Net	$1,37 \times 1,37$ mm	396×396	2D presek
modifikovani 2D U-Net	$1,37 \times 1,37$ mm	396×396	2D presek
modifikovani 3D U-Net	$5,0 \times 2,5 \times 2,5$ mm	$60 \times 204 \times 204$	3D volumen


2.4 Arhitekture neuronskih mreža

2.4.1 FCN-8

Potpuno konvoluciona mreža (eng *Fully Convolutional Network*) zamenjuje potpuno povezane slojeve klasifikacione mreže konvolucijama i time omogućava gustu predikciju klase za svaki piksel [9]. Ulaz FCN-8 je jedan standardizovan MR presek veličine 224×224 . Enkoder ima pet VGG-stil blokova širina 64, 128, 256, 512 i 512 kanala; prva dva bloka sadrže po dve, a naredna tri po tri konvolucije 3×3 sa dopunom jedan. Iza svakog bloka sledi maksimalno sažimanje 2×2 sa korakom dva, pa prostorna rezolucija redom prelazi sa 224 na 112, 56, 28, 14 i 7 piksela.

Klasifikaciona glava na mapi 7×7 koristi konvoluciju 7×7 sa 1024 kanala, ReLU i *dropout* 0,5, zatim konvoluciju 1×1 sa 1024 kanala, ReLU i *dropout*

0,5, a na kraju konvoluciju 1×1 sa četiri logita. Dve bočne grane pretvaraju izlaze pool3 (256 kanala, 28×28) i pool4 (512 kanala, 14×14) u četiri logita konvolucijom 1×1 . Duboki rezultat se transponovanom konvolucijom 4×4 , koraka dva, dovodi na nivo pool4 i sabira sa njegovim skorom; isti postupak se ponavlja do pool3. Završna transponovana konvolucija 16×16 , koraka osam, vraća četiri logita na izvornu rezoluciju. Sve obične konvolucije koriste *batch* normalizaciju i ReLU; transponovane konvolucije se inicijalizuju bilinearnim filtrom. Ukupno se optimizuje 41 474 508 parametara. Raspored enkodera, bočnih grana i dekodera skorova prikazan je na Sl. 4.



Slika 4: Šema arhitekture FCN-8. Plava putanja izdvaja obeležja, narandžasta vraća prostornu rezoluciju, a zelene isprekidane grane projektuju pool3 i pool4 mape na četiri klasna skora. Krugovi označavaju sabiranje.


2.4.2 Standardni i modifikovani 2D U-Net

U-Net ima kontrakcionu putanju za izdvajanje konteksta i simetričnu ekspanzionu putanju za preciznu lokalizaciju [10]. Standardni 2D model prima $1 \times 396 \times 396$ i koristi osnovnu širinu 64. Enkoder se sastoji od četiri bloka sa po dve konvolucije 3×3 , *batch* normalizacijom i ReLU aktivacijom, sa 64, 128, 256 i 512 kanala. Maksimalna sažimanja 2×2 daju mape dimenzija 396, 198, 99 i 49, a nakon četvrtog sažimanja usko grlo sa 1024 kanala radi na 24×24 . Neparne dimenzije 99 i 49 potiču od ulaza 396; pri dekodovanju se, kada je potrebno, mapa bilinearnom interpolacijom usklađuje sa dimenzijom preskočne grane.

Dekoder ima četiri nivoa. Na svakom se transponovanom konvolucijom 2×2 , koraka dva, prepolovi broj kanala (1024--512--256--128--64), rezultat se nadovezuje sa odgovarajućom enkoderskom mapom, pa dve konvolucije 3×3 obrađuju spojene kanale. Završna konvolucija 1×1 preslikava 64 kanala u četiri logita: pozadinu, RV, Myo i LV. Standardni 2D U-Net ima 31 044 484 parametara.

Modifikovani 2D U-Net ima potpuno isti ulaz, enkoder, usko grlo i izlazne širine dekodorskih blokova. Razlika je samo u svakoj od četiri transponovane konvolucije: umesto 512, 256, 128 i 64 kanala, one daju četiri kanala, koliko postoji klasa. Posle nadovezivanja širine spojenih mapa su 516, 260, 132 i 68 kanala, a naredni par konvolucija ih ponovo svodi na 512, 256, 128 i 64. Tako se sužava najskuplji deo dekodorske putanje bez promene izlazne rezolucije. Model ima 25 188 212 parametara, 5 856 272 manje od standardnog 2D U-Net-a, odnosno

približno 18,9% manje. Zajednički raspored slojeva dve 2D U-Net varijante prikazan je na Sl. 5.




Slika 5: Zajednička šema standardnog i modifikovanog 2D U-Net-a. U oznakama std. i mod. par vrednosti predstavlja broj kanala posle transponovane konvolucije i posle nadovezivanja; izlaz bloka isti je u obe varijante.

2.4.3 Anizotropni 3D U-Net

3D U-Net koristi volumetrijske operacije i neposredno uzima u obzir kontekst susednih preseka [11]. Ulaz je jedan resamplovan i dopunjen volumen $1 \times 60 \times 204 \times 204$ u poretku $\text{kanali} \times Z \times Y \times X$. Osnovna širina je 16, pa četiri enkoderska bloka sa po dve konvolucije $3 \times 3 \times 3$, *batch* normalizacijom i ReLU aktivacijom daju 16, 32, 64 i 128 kanala. Usko grlo ima 256 kanala. Standardno sažimanje faktorom dva po svim osama brzo bi uklonilo malobrojne preseke ACDC volumena; zato je samo prvo maksimalno sažimanje (2, 2, 2), dok naredna tri imaju jezgro i korak (1, 2, 2).

Tako se dimenzija kroz ravan menja $60 \rightarrow 30 \rightarrow 30 \rightarrow 30 \rightarrow 30$, dok dimenzije u ravni prolaze kroz $204 \rightarrow 102 \rightarrow 51 \rightarrow 25 \rightarrow 12$. Dekoder je ogledalan: prve tri transponovane konvolucije imaju korak (1, 2, 2), a poslednja (2, 2, 2), uz preskočne veze i dve konvolucije po nivou. Kada deljenje neparne dimenzije da 25 odnosno 51, trilinearna interpolacija usklađuje izlaz dekonvolucije sa enkoderskom mapom pre nadovezivanja. Konvolucija $1 \times 1 \times 1$ preslikava završnih 16 kanala u četiri klase. Model ima 5 476 356 parametara; to je znatno manje od 2D varijanti, ali trodimenzionalne aktivacije pri volumenu $60 \times 204 \times 204$ objašnjavaju *mini-batch* veličine jedan i veći memorijski zahtev. Anizotropno sažimanje i nadodabiranje kroz volumen prikazani su na Sl. 6.



Slika 6: Šema anizotropnog 3D U-Net-a. Podebljani koraci (2, 2, 2) označavaju jedino sažimanje i odgovarajuće nadodabiranje duž ose preseka Z ; na ostalim nivoima menja se samo rezolucija u ravni. Zelene isprekidane veze nadovezuju enkoderske mape na dekoderske.

Tabela 3: Parametri realizovanih mreža. BN označava *batch* normalizaciju, a s korak.

Model	Sastav i ključni hiperparametri	Broj parametara
FCN-8	Ulaz 1×224^2 ; VGG blokovi 64--128--256--512--512; 2/2/3/3/3 konv. 3^2 ; glava 1024--1024--4, <i>dropout</i> 0,5; <i>pool</i> 2^2 , preskočne veze <i>pool3/pool4</i>	41 474 508
2D U-Net	Ulaz 1×396^2 ; kanali 64--128--256--512--1024; dva $3^2 + \text{BN} + \text{ReLU}$ po bloku; <i>pool/dekonv.</i> 2^2 , $s = 2$; nadovezivanje preskočnih veza	31 044 484
modifikovani 2D U-Net	Kao 2D U-Net, ali sve četiri dekonvolucije imaju izlaz od 4 kanala; dekoderski blokovi posle nadovezivanja ostaju 512--256--128--64	25 188 212
anizotropni 3D U-Net	Ulaz $1 \times 60 \times 204^2$; kanali 16--32--64--128--256; dva $3^3 + \text{BN} + \text{ReLU}$ po bloku; <i>pool/dekonv.</i> (2, 2, 2) jednom, zatim (1, 2, 2)	5 476 356

2.5 Funkcije gubitka i obučavanje

Za optimizaciju parametara mreža koristi se višeklasna unakrsna entropija, definisana izrazom

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_{nk} \log p_{nk}, \quad (2)$$

gde je t_{nk} binarna referentna oznaka, a p_{nk} *softmax* verovatnoća za N lokacija i K klasa. Za FCN-8, standardni 2D U-Net i 3D U-Net korišćena je standardna unakrsna entropija. Pošto pozadina zauzima mnogo više piksela od srčanih struktura, modifikovani 2D U-Net koristi ponderisanu entropiju sa težinom 0,1 za pozadinu i 0,3 za svaku ciljnu klasu. Time greške na RV, miokardu i LV dobijaju veći relativni uticaj.

Svi modeli koriste *batch* normalizaciju posle konvolucionih i transponovanih

konvolucionih slojeva. Optimizacija je izvedena Adam algoritmom, a korak učenja se smanjuje *ReduceLROnPlateau* rasporedom. Sačuvana podešavanja eksperimenata data su u Tabeli 4. Sve obuke izvršene su na CUDA grafičkom procesoru, sa semenom 42 i bez težinske regularizacije.

Tabela 4: Podešavanja *spacing-aware* eksperimenata.

Model	Epohe	Mini-batch	Korak učenja	Parametri	Gubitak
FCN-8	100	4	0,01	41 474 508	CE
2D U-Net	100	2	0,01	31 044 484	CE
mod. 2D U-Net	100	2	0,01	25 188 212	ponderisana CE
mod. 3D U-Net	100	1	0,01	5 476 356	CE

Svi modeli koriste Adam i ReduceLROnPlateau raspored koraka. Za svaki *fold* čuvaju se težine modela iz epohe sa najboljim validacionim *foreground Dice* rezultatom. Za završnu procenu na pacijentima 101--150 prosečavaju se *softmax* verovatnoće pet tako izabranih modela istog tipa, zatim se primenjuju *argmax* i postobrada.

2.6 Rekonstrukcija volumena i postobrada

Metrike prijavljene tokom obuke 2D mreža računaju se nad presecima u *mini-batch-evima* i zato nisu dovoljne za poređenje sa volumetrijskim rezultatima. Tokom evaluacije preseki se grupišu prema identifikatoru pacijenta i broju vremenskog okvira, uređuju po anatomskom položaju i slažu u 3D masku. Za 3D U-Net predikcija je već volumetrijska.

U automatskim maskama povremeno se pojavljuju mala izolovana ostrva. Za svaku *foreground* klasu izdvaja se šest-susedstvom najveća povezana komponenta, dok se ostali vokseli vraćaju u pozadinu. Ovakav postupak smanjuje osetljivost Hausdorffovog rastojanja za udaljene lažno pozitivne komponente.

2.7 Mere kvaliteta

Dice meri preklapanje regiona, dok *Acerage Symmetric Surface Distance* (ASSD) i Hausdorffovo Rastojanje (HD) (eng. *hausdorff Distance*) koriste položaj granice [12]. Za predikciju P i referencu G , *Dice* meri preklapanje:

$$Dice(P, G) = \frac{2|P \cap G|}{|P| + |G|}. \quad (3)$$

Vrednost jedan označava potpuno preklapanje, a nula odsustvo preklapanja. Srednji *foreground Dice* u ovom radu predstavlja prosek za RV, miokard i LV najpre unutar volumena, a zatim preko volumena jednog *folda*.

Ako su S_P i S_G skupovi tačaka na površinama maski, a $d(x, S) = \min_{y \in S} \|x - y\|$,

prosečno simetrično rastojanje površina iznosi

$$ASSD(P, G) = \frac{\sum_{p \in S_P} d(p, S_G) + \sum_{g \in S_G} d(g, S_P)}{|S_P| + |S_G|}, \quad (4)$$

dok je Hausdorffovo rastojanje

$$HD(P, G) = \max \left\{ \max_{p \in S_P} d(p, S_G), \max_{g \in S_G} d(g, S_P) \right\}. \quad (5)$$

HD opisuje najgoru graničnu grešku i veoma je osetljiv na izdvojene tačke, dok ASSD predstavlja prosečnu grešku konture. Oba rastojanja računaju se sa stvarnim $Z/Y/X$ razmakom i prijavljuju u milimetrima; *epoch-level 2D Dice* služi samo za praćenje obuke.

3 REZULTATI I DISKUSIJA

3.1 Poređenje arhitektura


Tabela 5 prikazuje srednju vrednost i standardnu devijaciju preko pet *foldova*. Standardni 2D U-Net ostvaruje najbolji srednji *Dice* i najmanji ASSD i HD. Modifikovani 2D U-Net ima skoro isti *Dice*, ali nešto veće granične udaljenosti. Anizotropni 3D U-Net ima najveću varijabilnost i slabije rezultate, naročito za RV i miokard. Grafičko poređenje makro *Dice* koeficijenta i rezultata po strukturama dato je na Sl. 7.

Tabela 5: Makro rezultati na pet validacionih *foldova*; srednja vrednost $\pm$ SD.

Model	<i>Dice</i>	ASSD [mm]	HD [mm]
FCN-8	$0,8810 \pm 0,0105$	$0,9210 \pm 0,1699$	$11,8831 \pm 1,1820$
2D U-Net	$0,9025 \pm 0,0064$	$0,7532 \pm 0,1108$	$10,5616 \pm 0,7197$
mod. 2D U-Net	$0,9006 \pm 0,0043$	$0,7807 \pm 0,0437$	$10,5887 \pm 0,4396$
mod. 3D U-Net	$0,8407 \pm 0,0176$	$1,8843 \pm 0,3567$	$13,2831 \pm 0,8333$

Tabela 6: *Dice* po anatomskim strukturama u petostruko validaciji; srednja vrednost $\pm$ SD.

Model	RV	Miokard	LV
FCN-8	$0,8613 \pm 0,0137$	$0,8557 \pm 0,0112$	$0,9261 \pm 0,0103$
2D U-Net	$0,8843 \pm 0,0112$	$0,8838 \pm 0,0060$	$0,9393 \pm 0,0074$
mod. 2D U-Net	$0,8858 \pm 0,0054$	$0,8803 \pm 0,0067$	$0,9357 \pm 0,0034$
mod. 3D U-Net	$0,8197 \pm 0,0228$	$0,8088 \pm 0,0184$	$0,8937 \pm 0,0168$



Slika 7: Poređenje modela: makro *foreground Dice* i *Dice* po strukturama. Tačke i trake greške prikazuju pet *foldova*.

Standardni 2D U-Net ima najbolji makro rezultat, ali je razlika u odnosu na modifikovani 2D U-Net mala: 0,0019 *Dice* poena. Modifikovana arhitektura postiže najbolji RV *Dice*, uz približno 18,9% manje parametara. LV je najlakša struktura za segmentaciju kod svih modela, dok su RV i miokard osetljiviji na nepravilnu geometriju, tanak zid i delimični volumenski efekat. Sličan obrazac prijavljen je i u izvornom radu [4].

Tabela 7: Makro *foreground Dice* po validacionom *foldu*. Svaka vrednost nastaje iz 40 rekonstruisanih ED/ES volumena 20 validacionih pacijenata.

Model	<i>fold</i> 0	<i>fold</i> 1	<i>fold</i> 2	<i>fold</i> 3	<i>fold</i> 4
FCN-8	0,8953	0,8640	0,8868	0,8760	0,8831
2D U-Net	0,9088	0,8918	0,9081	0,9047	0,8990
mod. 2D U-Net	0,8989	0,8937	0,9071	0,9016	0,9017
mod. 3D U-Net	0,8471	0,8302	0,8118	0,8601	0,8543

3.1.1 FCN-8

FCN-8 postiže CV *Dice* $0,8810 \pm 0,0105$, ASSD $0,9210 \pm 0,1699$ mm i HD $11,8831 \pm 1,1820$ mm. Najslabiji *fold* je *fold* 1 (*Dice* 0,8640), koji istovremeno ima najveći ASSD 1,1703 mm i HD 13,7664 mm. Po klasama, LV je najstabilnija struktura (*Dice* $0,9261 \pm 0,0103$), dok su RV i Myo na 0,8613 i 0,8557. Ansambl pet FCN-8 modela na 100 odvojenih volumena poboljšava *Dice* na 0,8934 i smanjuje HD na 10,5639 mm, ali zaostaje za obe 2D U-Net varijante.

3.1.2 Standardni 2D U-Net

Standardni 2D U-Net daje najbolji CV rezultat: *Dice* $0,9025 \pm 0,0064$, ASSD $0,7532 \pm 0,1108$ mm i HD $10,5616 \pm 0,7197$ mm. *Dice* je u svih pet *foldova* između 0,8918 i 0,9088, što pokazuje manju zavisnost od sastava validacionog podskupa nego kod FCN-8 i 3D modela. Ima najbolji LV rezultat (0,9393), a Myo *Dice* 0,8838 je

praktično jednak RV rezultatu 0,8843. Na lokalno odvojenom skupu petomodelni ansambl zadržava prvo mesto: *Dice* 0,9109, ASSD 0,7613 mm i HD 9,8436 mm.

3.1.3 Modifikovani 2D U-Net

Suženi dekodер postiže CV *Dice* $0,9006 \pm 0,0043$, samo 0,0019 ispod standardnog 2D U-Net-a, uz najmanju varijabilnost između *foldova*. Najbolji je *fold* 2 sa *Dice* 0,9071, a raspon između najnižeg i najvišeg *folda* je 0,0134. Modifikovani model ima najbolji RV *Dice* (0,8858), dok su Myo i LV *Dice* 0,8803 i 0,9357. Petomodelni ansambl ostvaruje *Dice* 0,9085, ASSD 0,8096 mm i HD 9,8810 mm. Rezultat pokazuje da se približno petina parametara dekodera može ukloniti uz vrlo malu promenu preklapanja, uz skromno veće prosečne granične greške od standardnog modela.


3.1.4 Anizotropni 3D U-Net

Anizotropni 3D U-Net postiže CV *Dice* $0,8407 \pm 0,0176$, ASSD $1,8843 \pm 0,3567$ mm i HD $13,2831 \pm 0,8333$ mm. Najteži je *fold* 2, sa *Dice* 0,8118 i ASSD 2,5448 mm; to doprinosi najvećoj standardnoj devijaciji među upoređenim modelima. Po klasama su RV (0,8197) i Myo (0,8088) znatno slabiji od LV (0,8937), što ukazuje da dodatni kontekst kroz preseke ne nadoknađuje mali broj volumena i izraženu anizotropiju. Na test pacijentima ansambl poboljšava *Dice* na 0,8583 i ASSD na 1,4895 mm, ali i dalje ostaje iza 2D pristupa.

3.2 Uticaj petostruke validacije

Za razliku od jedne fiksne podele, pet *foldova* omogućava da svaki trening pacijent bude validacioni tačno jednom. Zato se uz srednju vrednost prijavljuje i standardna devijacija između *foldova*. Kod standardnog 2D U-Net-a makro *Dice* iznosi $0,9025 \pm 0,0064$ preko pet validacionih podskupova. Modifikovani 2D U-Net ima najmanju standardnu devijaciju *Dice*-a, 0,0043, dok 3D U-Net pokazuje najveću, 0,0176.

Raspodela ASSD i HD, prikazana na Sl. 8, dodatno pokazuje zašto *Dice* sam nije dovoljan. Dva modela mogu imati slično preklapanje regiona, ali različitu najveću grešku granice. Kod 3D U-Net-a posebno se izdvaja jedan teži *fold* sa većim ASSD, što je u skladu sa osetljivošću volumetrijske obuke na mali broj uzoraka i *mini-batch* veličine jedan.



Slika 8: Raspodela volumetrijskih metrika između pet *foldova*.

3.3 Završna evaluacija ansambla


Za svaki model je pet *fold* modela iz epoha sa najboljim validacionim rezultatom objedinjeno prosekom *softmax* verovatnoća. Tabela 8 prikazuje rezultat na 50 lokalno označenih test pacijenata, odnosno 100 ED/ES volumena. Standardni 2D U-Net zadržava prednost na odvojenom skupu. Ovi rezultati predstavljaju završnu lokalnu proveru.

Tabela 8: Petomodelni ansambl na 100 odvojenih test volumena.

Model	<i>Dice</i>	ASSD [mm]	HD [mm]
FCN-8	0,8934	0,8937	10,5639
2D U-Net	0,9109	0,7613	9,8436
mod. 2D U-Net	0,9085	0,8096	9,8810
mod. 3D U-Net	0,8583	1,4895	11,4728

3.4 Krive učenja

Sl. 9 prikazuje srednje vrednosti validacionog *Dice* koeficijenta po presecima i njegovu standardnu devijaciju kroz *foldove*. Krive služe za praćenje toka obuke. Najveći skokovi kod 3D mreže saglasni su sa malim *mini-batch*-em i manjim brojem volumetrijskih uzoraka.




Slika 9: Srednji validacioni *foreground Dice* po prescima tokom obuke.

Kod 2D modela validacioni *Dice* se ranije ujednačava nego kod 3D modela. Krive služe za izbor kontrolne tačke u svakom *foldu*, ali ne i za konačno poređenje arhitektura; za to se koriste rekonstruisani 3D volumeni iz Tabela 5 i 8.


3.5 Kvalitativna analiza predikcija

Za poređenje svih arhitektura bira se po jedan unapred određen ED slučaj iz svakog validacionog *folda*: pacijenti 047, 051, 059, 052 i 055 za *foldove* 0--4. U svakom *foldu* bira se srednji pacijent po sortiranom identifikatoru, pa nijedan primer nije ručno izabran prema izgledu predikcije. Svaka mreža koristi samo težine odgovarajućeg *folda*, dakle nijedna nije učena na pacijentu prikazanom u svom redu. Zbog različite *spacing-aware* predobrade, preseki 2D i 3D modela nisu nužno na identičnom izvornom *Z* položaju; za svaki prikaz bira se centralni presek sa najvećom površinom ekspertske *foreground* maske u reprezentaciji odgovarajućeg modela. Kvalitativno poređenje sva četiri modela na izabranim slučajevima prikazano je na Sl. 10.



Slika 10: Kvalitativno *out-of-fold* poređenje sva četiri modela na po jednom ED pacijentu iz svakog od pet *foldova*. Kolone predstavljaju ulaznu MR sliku, postprocesirane predikcije i ekspertsku masku; volumetrijski *foreground Dice* je naveden u svakoj predikcijskoj ćeliji.

Kvalitativni prikaz dopunjuje volumetrijske tabele. Standardni 2D U-Net ima najveći *Dice* u *foldovima* 0, 1, 3 i 4 (0,910; 0,930; 0,886; 0,910), dok modifikovani 2D U-Net daje najbolji prikaz u *foldu* 2 (0,945). U obe 2D varijante konture LV i miokarda prate ekspertsku masku kroz svih pet primera, što vizuelno potvrđuje malu razliku njihovih prosečnih CV rezultata. FCN-8 je naročito slabiji na pacijentu 052 iz *folda* 3 (0,798), gde je vidljivo šire izdvajanje RV i miokarda u odnosu na referencu. Anizotropni 3D U-Net pokazuje najveću promenu između slučajeva: na pacijentu 047 dobija *Dice* 0,584 uz izrazito nepotpunu segmentaciju, dok na pacijentu 059 dostiže 0,915. Takva promenljivost je saglasna sa najvećom *fold-level* standardnom devijacijom ovog modela u Tabeli 5. Posebnu pažnju treba obratiti na kontinuitet tankog miokarda, granice RV i male strukture pri vrhu i bazi, jer su upravo te oblasti najosetljivije na razlike između arhitektura i odgovaraju slabijim klasnim rezultatima. Detaljniji primer predikcije standardnog 2D U-Net-a kroz ceo volumen prikazan je na Sl. 11.



Slika 11: *Out-of-fold* predikcije standardnog 2D U-Net-a i ekspertske maske kroz ED volumen pacijenta 002. Slučaj je deterministički izabran kao medijanski prema volumetrijskom *foreground Dice*-u među svim ED validacionim volumenima.

Prikazani pacijent 002 pripada validacionom *foldu* 2 i predviđen je kontrolnim *snapshot*-om iz epohe 39; srednji volumetrijski *foreground Dice* iznosi 0,9276. Pošto model nije treniran na ovom pacijentu, prikaz je *out-of-fold* procena, a ne primer iz skupa za obuku. U centralnim presecima, gde su strukture velike i kontrastne, slaganje je veoma dobro. Veće razlike očekivano se javljaju

pri bazi i vrhu, gde strukture zauzimaju mali broj piksela i brzo menjaju oblik između preseka. Miokard je posebno osetljiv, jer mala greška unutrašnje ili spoljne konture značajno menja preklapanje.

3.6 Diskusija

U radu je realizovan *spacing-aware* postupak za automatsku segmentaciju LV, RV i miokarda na ACDC *cine-MR* snimcima. Prostorni metapodaci su sačuvani tokom konverzije, a četiri arhitekture – FCN-8, standardni i modifikovani 2D U-Net i anizotropni 3D U-Net – ocenjene su petostrukom validacijom nad rekonstruisanim ED/ES volumenima. Standardni 2D U-Net ostvario je najbolji srednji CV *Dice* od 0,9025, dok je njegov petomodelni ansambl na odvojenom test skupu dostigao *Dice* 0,9109. U nastavku se ovi nalazi sagledavaju u odnosu na referentni rad i rezultate drugih metoda na ACDC izazovu.

3.6.1 Poređenje sa referentnim radom

Poređenje sa Baumgartnerom i saradnicima u Tabeli 9 ima primarno kontekstualni karakter. Pošto se protokol ovog rada razlikuje po tome što je u ovom radu korišćen potomodalni ansambl modela. Takođe postupak referentnog rada nije detaljno opisan, stoga je bilo neophodno doneti odluke o treniranju i hiperparametrima modela koji se potencijalno razlikuju u odnosu na izvorni rad. Ipak, odnos 2D i 3D pristupa ostaje sličan: 2D modeli dobro čuvaju detalje u ravni, dok 3D model plaća cenu anizotropije i većih memorijskih zahteva.

Tabela 9: CV *Dice* ovog rada i ED/ES prosek rezultata izvornog rada [4]; poređenje je orijentaciono.

Arhitektura	Ovaj rad	Izvorni rad	Razlika
FCN-8	0,881	0,902	−0,021
2D U-Net	0,902	0,911	−0,009
modifikovani 2D U-Net	0,901	0,914	−0,013
anizotropni 3D U-Net	0,841	0,859	−0,018

3.6.2 Poređenje sa drugim ACDC takmičarima

Organizatori ACDC izazova objavili su jedinstvenu evaluaciju deset pristiglih metoda na skrivenom test skupu od 50 pacijenata [5]. Tabela 10 sažima preostale takmičarske pristupe. Makro *Dice* u tabeli je naknadno izračunat kao neponderisani prosek šest objavljenih *Dice* vrednosti (LV, RV i Myo u ED i ES), dok je srednje HD rastojanje prosek odgovarajućih šest vrednosti u milimetrima. Nijedna od ove dve agregirane mere nije bila zvanična rang-metrika izazova.

Tabela 10: Kontekstualno poređenje sa drugim ACDC takmičarima: zvanični skriveni test skup i izvedene agregirane mere [5]; podebljan je lokalni rezultat ovog rada.

Metoda	Makro <i>Dice</i>	Srednje HD [mm]
Isensee i sar. (ansambl 2D i anizotropnih 3D U-Net-ova)	0,928	9,0
Khened i sar. (gusti 2D U-Net)	0,914	11,2
Jang i sar. (2D M-Net)	0,911	9,7
Zotti i sar. (2D GridNet sa priorom oblika)	0,911	9,6
Ovaj rad (petomodelni ansambl standardnog 2D U-Net-a)	0,9109	9,8436
Wolterink i sar. (2D dilatirana CNN)	0,908	10,7
Patravali, Jain i Chilamkurthy (2D U-Net)	0,892	12,1
Rohé, Sermesant i Pennec (višestruki atlas)	0,892	12,1
Tziritas i Grinias (nivoi skupova i MRF)	0,836	15,8

Najbolji takmičarski rezultat postiže ansambl 2D i anizotropnih 3D U-Net-ova Isensee i saradnika. Više 2D varijanti zauzima gornji deo tabele, što je saglasno sa nalazom ovog rada da standardni 2D U-Net najbolje koristi izrazito anizotropne ACDC snimke. U svim metodama LV je uglavnom lakša struktura, dok su miokard i RV u ES zahtevniji zbog tankog zida, nepravilnijeg oblika i manjeg preseka.

Petomodelni ansambl standardnog 2D U-Net-a ovog rada ostvaruje *Dice* 0,9109 i HD 9,8436 mm na lokalno označenih 50 pacijenata 101--150. Te vrednosti su brojučano bliske grupi jakih originalnih 2D pristupa, ali se ne smeju tumačiti kao plasman na tabeli: takmičari su ocenjeni zvaničnim slepim evaluatorom na skrivenom test skupu, dok su ovde reference dostupne lokalno, a predobrada, postobrada i agregiranje metrika nisu nužno identični.

3.7 Ograničenja i mogućnosti unapređenja

Petostruka validacija meri varijabilnost rezultata između podela, ali ograničen broj *foldova* i dalje ne predstavlja nezavisnu kliničku studiju. Dalji rad može obuhvatiti augmentaciju, kombinovane *Dice*-CE gubitke, 95-procentni HD, analizu neuspešnih slučajeva i izračunavanje kliničkih zapremina.

Posebno obećavajući pravac je *transfer* učenje. Umesto inicijalizacije svih težina slučajnim vrednostima, enkoder 2D mreže može se preuzeti iz prethodno obučene konvolucione mreže, a zatim dotrenirati za segmentaciju srca. Takav postupak obično ubrzava konvergenciju i može poboljšati prepoznavanje ivica i tekstura, naročito kada je broj označenih snimaka ograničen. Potrebno je prilagoditi prvi sloj jednokanalnom MR ulazu, a pri dotreniravanju koristiti manji korak učenja za prethodno obučene slojeve i veći za novu dekodersku i klasifikacionu glavu.

Transformerski modeli predstavljaju drugu moguću nadogradnju. Za razliku od konvolucija koje lokalno obrađuju ograničeno susedstvo, mehanizam pažnje može direktno povezati udaljene oblasti slike ili volumena i tako obezbediti širi

prostorni kontekst. Hibridni *CNN--transformer* modeli, kao i segmentacione arhitekture zasnovane na prozorima pažnje, mogli bi da poboljšaju kontinuitet miokarda i razdvajanje RV od okolnih struktura. Njihovu veću računarsku složenost treba uravnotežiti hijerarhijskom pažnjom, manjim *patch*-evima i dotreniravanjem prethodno obučениh težina.

4 ZAKLJUČAK

Realizovan je *spacing-aware* postupak za automatsku višeklasnu segmentaciju srčanih struktura na ACDC *cine-MR* snimcima. Prostorni metapodaci sačuvani su tokom konverzije, 2D i 3D ulazi normalizovani su na fizičku skalu, a kvalitet je procenjen na rekonstruisanim volumenima sa rastojanjima u milimetrima.

Deterministička dijagnostički stratifikovana petostruka validacija omogućava procenu varijabilnosti rezultata između *foldova*. Standardni 2D U-Net postiže najveći srednji CV *Dice*, $0,9025 \pm 0,0064$, i najveći *Dice* petomodelnog ansambla na odvojenim test pacijentima, 0,9109. Modifikovani 2D U-Net ostvaruje sličan rezultat uz manji broj parametara, dok anizotropni 3D U-Net u korišćenoj konfiguraciji ostvaruje slabiji rezultat.

Rezultati pokazuju da je za posmatrane anizotropne *cine-MR* volumene 2D segmentacija pogodnija od korišćene 3D varijante. Razmak kroz preseke je znatno veći od razmaka unutar ravni, pa susedni preseci nose manje pouzdanog lokalnog prostornog kontinuiteta nego susedni pikseli u ravni. 2D modeli zato uče iz većeg broja preseka, koriste ulaze više *in-plane* rezolucije i ne troše kapacitet na interpolisani kontekst kroz ravan. Nasuprot tome, 3D model obrađuje manje nezavisnih volumena, zahteva *mini-batch* veličine jedan zbog većih aktivacija i osetljiviji je na promenu oblika struktura između udaljenih preseka. Anizotropne operacije ublažavaju ovaj problem, ali ga ne uklanjaju u potpunosti; to se vidi u nižem *Dice*-u i većoj varijabilnosti 3D rezultata.

Segmentacione maske imaju neposrednu kliničku vrednost, jer omogućavaju računanje zapremine LV i RV u ED i ES, a zatim udarnog volumena i ejekcione frakcije. Zapremina se dobija sabiranjem zapremine vokselu unutar odgovarajuće komore, pri čemu se koriste stvarni prostorni razmaci. Iz LV miokardne maske može se izračunati i masa miokarda množenjem zapremine miokarda gustinom srčanog mišića. Zato greške segmentacije, posebno na granici miokarda i pri bazi i vrhu komora, ne utiču samo na *Dice* već se mogu preneti na izvedene kliničke pokazatelje.

Završni rezultat ansambla dodatno pokazuje korist kombinovanja pet modela. Svaki model je obučен na drugačijem skupu od 80 pacijenata i može napraviti različitu lokalnu grešku; prosečenje njihovih *softmax* verovatnoća smanjuje uticaj pojedinačne nestabilne predikcije pre konačnog izbora klase i postobrade. Kod standardnog 2D U-Net-a takav ansambl dostiže *Dice* 0,9109 na odvojenim pacijentima, u odnosu na prosečni CV *Dice* 0,9025 pojedinačnih *fold-modela*. Iako ove dve procene nisu strogo iste evaluacije, rezultat je saglasan sa očekivanjem da ansambl daje stabilniju i robusniju segmentaciju.

Zaključak ne znači da je 3D pristup načelno slabiji, već da izbor dimenzije modela mora pratiti fizičku rezoluciju snimanja, dostupni broj uzoraka i memorijski budžet. U scenariju sa gušćim presecima ili većim brojem volumena, 3D odnosno hibridni 2D--3D modeli mogli bi bolje iskoristiti međupresečni kontekst. Sačuvane podele, prostorni metapodaci i podešavanja eksperimenata omogućavaju ponavljanje postupka, proveru ovih pretpostavki i poređenje narednih arhitektura pod istim protokolom.

5 LITERATURA

Bibliografija

- [1] J. Schulz-Menger, D. A. Bluemke, J. Bremerich, et al., "Standardized image interpretation and post-processing in cardiovascular magnetic resonance – 2020 update", *Journal of Cardiovascular Magnetic Resonance*, vol. 22, art. 19, 2020; i SCMR smernice za izveštavanje CMR pregleda, 2022. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9052489/>.
- [2] G. Litjens, T. Kooi, B. E. Bejnordi, et al., "A survey on deep learning in medical image analysis", *Medical Image Analysis*, vol. 42, str. 60--88, 2017. DOI: <https://doi.org/10.1016/j.media.2017.07.005>.
- [3] C. Chen, C. Qin, H. Qiu, G. Tarroni, J. Duan, W. Bai i D. Rueckert, "Deep Learning for Cardiac Image Segmentation: A Review", *Frontiers in Cardiovascular Medicine*, vol. 7, art. 25, 2020. DOI: <https://doi.org/10.3389/fcvm.2020.00025>.
- [4] C. F. Baumgartner, L. M. Koch, M. Pollefeys i E. Konukoglu, "An Exploration of 2D and 3D Deep Learning Techniques for Cardiac MR Image Segmentation", u *STACOM 2017*, LNCS 10663, str. 111--119, 2018. <https://arxiv.org/abs/1709.04496>.
- [5] O. Bernard, A. Lalande, C. Zotti, F. Cervenansky, et al., "Deep Learning Techniques for Automatic MRI Cardiac Multi-structures Segmentation and Diagnosis: Is the Problem Solved?", *IEEE Transactions on Medical Imaging*, vol. 37, no. 11, str. 2514--2525, 2018. DOI: <https://doi.org/10.1109/TMI.2018.2837502>.
- [6] F. Isensee, P. F. Jaeger, P. M. Full, I. Wolf, S. Engelhardt i K. H. Maier-Hein, "Automatic Cardiac Disease Assessment on cine-MRI via Time-Series Segmentation and Domain Specific Features", u *STACOM 2017*, LNCS 10663, str. 120--129, 2018. DOI: https://doi.org/10.1007/978-3-319-75541-0_13.
- [7] M. Khened, V. Alex i G. Krishnamurthi, "Densely Connected Fully Convolutional Network for Short-Axis Cardiac Cine MR Image Segmentation and Heart Diagnosis Using Random Forest", u *STACOM 2017*, LNCS 10663, str. 140--151, 2018. DOI: https://doi.org/10.1007/978-3-319-75541-0_15.
- [8] CREATIS, "Automated Cardiac Diagnosis Challenge (ACDC)", zvanična stranica baze i izazova. <https://humanheart-project.creatis.insa-lyon.fr/database/#collection/637218c173e9f0047faa00fb>. Pristupljeno: septembar 2026.
- [9] J. Long, E. Shelhamer i T. Darrell, "Fully Convolutional Networks for Semantic Segmentation", u *Proc. CVPR*, str. 3431--3440, 2015. https://openaccess.thecvf.com/content_cvpr_2015/html/Long_Fully_Convolutional_Networks_2015_CVPR_paper.html.
- [10] O. Ronneberger, P. Fischer i T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation", u *MICCAI*, LNCS 9351, str. 234--241, 2015. DOI: https://doi.org/10.1007/978-3-319-24574-4_28.
- [11] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox i O. Ronneberger, "3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation", u *MICCAI*, LNCS 9901, str. 424--432, 2016. DOI: https://doi.org/10.1007/978-3-319-46723-8_49.

- [12] A. A. Taha i A. Hanbury, "Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool", *BMC Medical Imaging*, vol. 15, art. 29, 2015. DOI: <https://doi.org/10.1186/s12880-015-0068-x>.