



Univerzitet u Beogradu
Elektrotehnički fakultet
Katedra za signale i sisteme



PROJEKAT

iz predmeta Analiza biomedicinske slike (13E054ABS)

Automatska segmentacija srčanih struktura na MR snimcima: 2D i 3D neuronske mreže na ACDC bazi

Student

Vladan Bašić, 2022/0395

Predmetni nastavnik

prof. dr Milica Janković

Beograd, septembar 2026. godine

REZIME

U ovom projektu realizovan je postupak automatske segmentacije desne komore, miokarda i leve komore na kinematografskim MR snimcima srca u kratkoj osi. Postupak obuhvata konverziju NIfTI podataka u HDF5 uz očuvanje prostornog razmaka vokseli i afine transformacije, resamplovanje, normalizaciju intenziteta, obuku neuronskih mreža i evaluaciju nakon rekonstrukcije celih trodimenzionalnih volumena. Posebna pažnja posvećena je promenljivoj i anizotropnoj rezoluciji ACDC baze.

Upoređeni su FCN-8, standardni 2D U-Net, modifikovani 2D U-Net i anizotropni 3D U-Net. Umesto jedne fiksne podele, 100 označenih trening pacijenata podeljeno je deterministički na pet dijagnostički stratifikovanih foldova. U svakom foldu obučava se na 80, a validira na 20 pacijenata; svaka od pet dijagnostičkih grupa zastupljena je sa 16/4 pacijenta. Najveći srednji volumetrijski Dice koeficijent u unakrsnoj validaciji postiže standardni 2D U-Net, $0,9025 \pm 0,0064$. Njegov ansambl od pet modela postiže Dice 0,9109 na odvojenih 50 test pacijenata.

Metrike Dice, ASSD i Hausdorffovo rastojanje računaju se na rekonstruisanim volumenima, nakon zadržavanja najveće povezane komponente svake ciljne klase. Rastojanja se računaju sa fizičkim razmakom u milimetrima. Rezultati pokazuju da normalizacija fizičke skale i procena varijabilnosti između foldova daju strožiju i ponovljiviju procenu kvaliteta od jedne validacione podele.

Sadržaj

REZIME	2
1 UVOD	4
2 METODOLOGIJA RADA	4
2.1 Baza podataka i podela	4
2.2 Konverzija, prostorni razmak i predobrada	5
2.3 Arhitekture, obučavanje i metrike	6
3 REZULTATI I DISKUSIJA	7
3.1 Petostruka unakrsna validacija	7
3.2 Završna evaluacija ansambla	8
3.3 Tok obučavanja i kvalitativna analiza	8
3.4 Poređenje sa izvornim radom	9
3.5 Ograničenja i mogućnosti unapređenja	9
4 ZAKLJUČAK	10
5 LITERATURA	11

1 UVOD

Kardiovaskularna magnetna rezonanca (CMR) omogućava neinvazivno sagledavanje anatomije i funkcije srca. Za određivanje zapremine komora, mase miokarda i ejekcione frakcije potrebno je precizno izdvojiti levu komoru (LV), desnu komoru (RV) i miokard (Myo). Krajnja dijastola (ED) odgovara najvećoj ispunjenosti komora, a krajnja sistola (ES) njihovoj najvećoj kontrakciji. Ako su V_{ED} i V_{ES} zapremine komore, ejekciona frakcija iznosi


$$EF = \frac{V_{ED} - V_{ES}}{V_{ED}} \cdot 100 \%. \quad (1)$$

Ručno iscertavanje kontura zahteva stručnost i vreme, pa automatska segmentacija svakom pikselu ili vokselu dodeljuje pozadinu, RV, miokard ili LV. Konvolucione neuronske mreže uče obeležja direktno iz slike i pogodne su za ovu gustu višeklasnu klasifikaciju [3]. ACDC volumeni su anizotropni: in-plane razmak je približno 0,703–1,953 mm, a razmak duž ose preseka 5–10 mm. Zato 2D i anizotropni 3D pristupi predstavljaju različite kompromise između lokalnih detalja, prostornog konteksta i memorijskih zahteva [2].

2 METODOLOGIJA RADA


2.1 Baza podataka i podela

Automatic Cardiac Diagnosis Challenge sadrži 150 cine-CMR pregleda sa ED i ES referencama za LV, RV i miokard [1, 8]. Sto pacijenata 001–100 korišćeno je isključivo za obuku i unakrsnu validaciju, dok 50 pacijenata 101–150 ostaje odvojeno za završnu lokalnu evaluaciju ansambla. Dijagnoze DCM, HCM, MINF, NOR i RV ravnomerno su zastupljene.



Slika 1: Primer trening volumena i ekspertske konture RV, miokarda i LV.


Pacijenti se dele sa semenom 42 na pet foldova. Svaki fold ima 80 pacijenata za obuku i 20 za validaciju, pri čemu su svi preseki i obe faze jednog pacijenta u istom foldu. Time se sprečava curenje informacija između obuke i validacije i omogućava procena varijabilnosti rezultata.



Slika 2: Broj validacionih pacijenata po dijagnozi u svakom foldu.

2.2 Konverzija, prostorni razmak i predobrada


NIFTI slike i maske prevode se u HDF5 uz čuvanje identifikatora pacijenta, dijagnoze, faze, oblika volumena, affine transformacije i razmaka u redosledu $Z \times Y \times X$. Prostorni razmak normalizuje fizičku skalu anatomije; ne uvodi se kao dodatni ulazni kanal mreže.



Slika 3: Raspodela izvornog razmaka voksel trening pacijenata. Crvene linije označavaju ciljne razmake 2D i 3D predobrade.

Za 2D mreže svaki presek se resampluje u ravni na $1,37 \times 1,37$ mm; FCN-8 koristi 224×224 , a oba U-Net modela 396×396 piksela. Za 3D model volumen se resampluje na $5,0 \times 2,5 \times 2,5$ mm i centralno dovodi na $60 \times 204 \times 204$ voksel. Na

slikama se koristi linearna, a na maskama interpolacija najbližeg suseda. Intenziteti se standardizuju po slici, dok se preveliki ulazi centralno isecaju, a manji dopunjuju nulama.



Slika 4: Blok dijagram spacing-aware sistema za segmentaciju.

2.3 Arhitekture, obučavanje i metrike

FCN-8 koristi VGG-stil blokove, preskočne veze sa pool3 i pool4 nivoa i završno nadodabiranje faktorom osam [4]. Standardni 2D U-Net ima simetrični enkoder-dekoder sa nadovezivanjem mapa obeležja [5]. Modifikovani 2D U-Net zadržava isti enkoder, ali transponovane konvolucije sužava na četiri kanala, čime se broj parametara smanjuje sa 31,04 na 25,19 miliona. Anizotropni 3D U-Net sažima duž ose preseka samo na prvom nivou, a zatim sa korakom (1, 2, 2) [6].

Tabela 1: Podešavanja spacing-aware eksperimenata.

Model	Epohe	Mini-grupa	Korak učenja	Parametri	Gubitak
FCN-8	100	4	0,01	41 474 508	CE
2D U-Net	100	2	0,01	31 044 484	CE
mod. 2D U-Net	100	2	0,01	25 188 212	ponderisana CE
mod. 3D U-Net	100	1	0,01	5 476 356	CE

Svi modeli koriste Adam i ReduceLROnPlateau raspored koraka. Najbolji kontrolni punkt svakog folda bira se prema validacionom foreground Dice rezultatu. Za završnu procenu na pacijentima 101–150 prosečavaju se softmax verovatnoće pet najboljih kontrolnih punktova istog modela, zatim se primenjuju argmax i postobrada.

Predikcije 2D preseka grupišu se po pacijentu i okviru, uređuju po položaju i rekonstruišu u volumen. Za svaku foreground klasu zadržava se najveća šest-susedna povezana komponenta. Dice meri preklapanje:

$$Dice(P, G) = \frac{2|P \cap G|}{|P| + |G|}. \quad (2)$$

ASSD meri prosečnu simetričnu udaljenost površina, a HD najveću udaljenost između površina [7]. Oba rastojanja računaju se sa stvarnim $Z/Y/X$ razmakom i prijavljuju u milimetrima. Stoga su volumetrijske metrike posle rekonstrukcije

autoritativne; epoch-level 2D Dice služi samo za praćenje obuke.

3 REZULTATI I DISKUSIJA

3.1 Petostruka unakrsna validacija


Tabela 2 prikazuje srednju vrednost i standardnu devijaciju preko pet foldova. Standardni 2D U-Net ostvaruje najbolji srednji Dice i najmanji ASSD i HD. Modifikovani 2D U-Net ima skoro isti Dice, ali nešto veće granične udaljenosti. Anizotropni 3D U-Net ima najveću varijabilnost i slabije rezultate, naročito za RV i miokard.

Tabela 2: Makro rezultati na pet validacionih foldova; srednja vrednost $\pm$ SD.


Model	Dice	ASSD [mm]	HD [mm]
FCN-8	$0,8810 \pm 0,0105$	$0,9210 \pm 0,1699$	$11,8831 \pm 1,1820$
2D U-Net	$0,9025 \pm 0,0064$	$0,7532 \pm 0,1108$	$10,5616 \pm 0,7197$
mod. 2D U-Net	$0,9006 \pm 0,0043$	$0,7807 \pm 0,0437$	$10,5887 \pm 0,4396$
mod. 3D U-Net	$0,8407 \pm 0,0176$	$1,8843 \pm 0,3567$	$13,2831 \pm 0,8333$

Tabela 3: Dice po anatomskim strukturama u petostrukovalidaciji; srednja vrednost $\pm$ SD.

Model	RV	Miokard	LV
FCN-8	$0,8613 \pm 0,0137$	$0,8557 \pm 0,0112$	$0,9261 \pm 0,0103$
2D U-Net	$0,8843 \pm 0,0112$	$0,8838 \pm 0,0060$	$0,9393 \pm 0,0074$
mod. 2D U-Net	$0,8858 \pm 0,0054$	$0,8803 \pm 0,0067$	$0,9357 \pm 0,0034$
mod. 3D U-Net	$0,8197 \pm 0,0228$	$0,8088 \pm 0,0184$	$0,8937 \pm 0,0168$



Slika 5: Poređenje modela: makro foreground Dice i Dice po strukturama. Tačke i trake greške prikazuju pet foldova.



Slika 6: Raspodela volumetrijskih metrika između pet foldova.

3.2 Završna evaluacija ansambla


Za svaki model je pet najboljih fold kontrolnih punktova objedinjeno prosekom softmax verovatnoća. Tabela 4 prikazuje rezultat na 50 lokalno označenih test pacijenata, odnosno 100 ED/ES volumena. Standardni 2D U-Net zadržava prednost na odvojenom skupu. Ovi rezultati su odvojeni od CV rezultata: oni predstavljaju završnu lokalnu proveru, a ne zvaničnu slepu evaluaciju ACDC izazova.

Tabela 4: Petomodelni ansambl na 100 odvojenih test volumena.

Model	Dice	ASSD [mm]	HD [mm]
FCN-8	0,8934	0,8937	10,5639
2D U-Net	0,9109	0,7613	9,8436
mod. 2D U-Net	0,9085	0,8096	9,8810
mod. 3D U-Net	0,8583	1,4895	11,4728

3.3 Tok obučavanja i kvalitativna analiza

Sl. 7 prikazuje srednje vrednosti validacionog Dice koeficijenta po presecima i njegovu standardnu devijaciju kroz foldove. Krive služe za proveru konvergencije i nisu zamena za volumetrijsku evaluaciju iz Tabela 2 i 4. Najveći skokovi kod 3D mreže saglasni su sa malom mini-grupom i manjim brojem volumetrijskih uzoraka.



Slika 7: Srednji validacioni foreground Dice po presecima tokom obuke; osenčeni pojas je SD između foldova.

Kvalitativni out-of-fold prikaz generiše se na računaru koji poseduje pet najboljih kontrolnih punktova pomoću `scripts/visualize_cv_oof_predictions.py`. U ovom radnom prostoru kontrolni punkтови nisu prisutni, pa se zastarela slika predikcija iz ranijeg eksperimenta ne koristi.

3.4 Poređenje sa izvornim radom

Poređenje sa Baumgartnerom i saradnicima u Tabeli 5 ima samo kontekstualni karakter. Objavljeni rezultati prosečavaju ED i ES protokolom koji nije identičan ovde korišćenju predobradi, izboru hiperparametara i evaluaciji pune Hausdorffove udaljenosti. Ipak, odnos 2D i 3D pristupa ostaje sličan: 2D modeli dobro čuvaju detalje u ravni, dok 3D model plaća cenu anizotropije i većih memorijskih zahteva.

Tabela 5: CV Dice ovog projekta i ED/ES prosek rezultata izvornog rada [2]; poređenje je orijentaciono.

Arhitektura	Ovaj projekat	Izvorni rad	Razlika
FCN-8	0,881	0,902	−0,021
2D U-Net	0,902	0,911	−0,009
modifikovani 2D U-Net	0,901	0,914	−0,013
anizotropni 3D U-Net	0,841	0,859	−0,018

3.5 Ograničenja i mogućnosti unapređenja

Petostruka validacija sada meri varijabilnost između podela, ali pet foldova i dalje dele isti skup od 100 pacijenata, pa ne predstavljaju nezavisne kliničke studije. Lokalne reference za pacijente 101–150 omogućavaju strogo odvojenu evaluaciju ansambla, ali ne zamenjuju zvanično slepi ACDC protokol. Dalji rad treba

da obuhvati augmentaciju, kombinovane Dice-CE gubitke, 95-procentni HD, analizu neuspješnih slučajeva, izračunavanje kliničkih zapremina i eksternu validaciju na drugim centrima.

4 ZAKLJUČAK

Realizovan je spacing-aware postupak za automatsku višeklasnu segmentaciju srčanih struktura na ACDC cine-MR snimcima. Prostorni metapodaci sačuvani su tokom konverzije, 2D i 3D ulazi normalizovani su na fizičku skalu, a kvalitet je procenjen na rekonstruisanim volumenima sa rastojanjima u milimetrima.

Deterministička dijagnostički stratifikovana petostruka validacija daje robusniju procenu od prethodne pojedinačne podele. Standardni 2D U-Net postiže najbolji CV Dice $0,9025 \pm 0,0064$ i najbolji rezultat petomodelnog ansambla na odvojenim test pacijentima, Dice 0,9109. Modifikovani 2D U-Net ostaje konkurentan uz manji broj parametara, dok anizotropni 3D U-Net pokazuje veći uticaj ograničenog broja volumetrijskih uzoraka. Projekat time pruža ponovljiv osnov za strožu validaciju i buduću kliničku analizu.

5 LITERATURA

Bibliografija

- [1] O. Bernard, A. Lalande, C. Zotti, F. Cervenansky, et al., "Deep Learning Techniques for Automatic MRI Cardiac Multi-structures Segmentation and Diagnosis: Is the Problem Solved?", *IEEE Transactions on Medical Imaging*, vol. 37, no. 11, str. 2514–2525, 2018. DOI: <https://doi.org/10.1109/TMI.2018.2837502>.
- [2] C. F. Baumgartner, L. M. Koch, M. Pollefeys i E. Konukoglu, "An Exploration of 2D and 3D Deep Learning Techniques for Cardiac MR Image Segmentation", u *STACOM 2017*, LNCS 10663, str. 111–119, 2018. <https://arxiv.org/abs/1709.04496>.
- [3] G. Litjens, T. Kooi, B. E. Bejnordi, et al., "A survey on deep learning in medical image analysis", *Medical Image Analysis*, vol. 42, str. 60–88, 2017. DOI: <https://doi.org/10.1016/j.media.2017.07.005>.
- [4] J. Long, E. Shelhamer i T. Darrell, "Fully Convolutional Networks for Semantic Segmentation", u *Proc. CVPR*, str. 3431–3440, 2015. https://openaccess.thecvf.com/content_cvpr_2015/html/Long_Fully_Convolutional_Networks_2015_CVPR_paper.html.
- [5] O. Ronneberger, P. Fischer i T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation", u *MICCAI*, LNCS 9351, str. 234–241, 2015. DOI: https://doi.org/10.1007/978-3-319-24574-4_28.
- [6] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox i O. Ronneberger, "3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation", u *MICCAI*, LNCS 9901, str. 424–432, 2016. DOI: https://doi.org/10.1007/978-3-319-46723-8_49.
- [7] A. A. Taha i A. Hanbury, "Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool", *BMC Medical Imaging*, vol. 15, art. 29, 2015. DOI: <https://doi.org/10.1186/s12880-015-0068-x>.
- [8] CREATIS, "Automated Cardiac Diagnosis Challenge (ACDC)", zvanična stranica baze i izazova. <https://www.creatis.insa-lyon.fr/Challenge/acdc/>. Pristupljeno: septembar 2026.